



# ALGORITMOS DE GERAÇÃO DE IMAGENS

DAVI V. C. PERDIGÃO  
EDMILSON L. CORDEIRO  
ERIC H. DE C. CHAVES



# TÓPICOS A DISCUTIR

01

## Introdução

Definição, Contexto e Aplicações Práticas

04

## Exemplos de Softwares

02

## Tipos de Algoritmos

Redes Generativas Adversariais (GANs), Redes Autoencoder, Redes Transformadoras

05

## Desafios e Limitações

Complicações, Problemas e Dependências

03

## Treinamento dos Algoritmos

06

## Aplicações Futuras

Simulações, Treinamento, Animações, entre outras.

07

## Conclusão



# INTRODUÇÃO



# DEFINIÇÃO

Algoritmos de geração de imagens são técnicas de aprendizado de máquina que permitem que as máquinas criem e interpretem imagens de forma autônoma.

# CONTEXTO


- Final dos anos 1950 – início do surgimento da computação gráfica da computação gráfica;
- Década de 1960 - Algoritmos de rasterização por Ivan Sutherland;
- Década de 1970 - Técnicas de modelagem de superfícies por Ed Catmull;
- Década de 1990 - Desenvolvimento das Redes Neurais Convolucionais (CNNs);

Figura 1: Exemplo de Imagem gerada pelo Digitus DGT-100.



Fonte: Museu Capixaba do Computador, 2022.

Figura 2: Scketchpad desenvolvido por Sutherland .



Fonte: Wikimedia, 2016.



Figura 3: Simulador de corrida com Realidade Virtual.



Fonte: Machado, 2017.

Figura 4: Realidade Virtual no treinamento de médicos.



Fonte: Forchesatto, 2022.

Figura 5: Realidade Virtual na construção civil.



Fonte: Halo, 2022.

# APLICAÇÕES PRÁTICAS

- Entretenimento;
- Medicina;
- Ambientes Virtuais Imersivos;
- Síntese de Imagens Históricas ou Ausentes.



# TIPOS DE ALGORÍTMOS



# REDES GENERATIVAS ADVERSARIAIS (GANs)



- Método poderoso para gerar dados sintéticos semelhantes aos reais;
- Treinamento adversarial de rede geradora e discriminadora;
- Geração de imagens, fala e texto sintético de alta qualidade;
- Implicações em criação visual e geração de texto personalizado;
- Duas redes neurais: Geradora (Generator) e Discriminadora (Discriminator);
- Objetivo: Gerar dados sintéticos semelhantes aos dados reais;



# PROCESSO DE TREINAMENTO



## FASE 1

- Gerador cria dados sintéticos;
- Discriminador aprende a distinguir dados reais dos sintéticos.



## FASE 2

- Gerador ajusta pesos com base nos erros do Discriminador;
- Gerador busca gerar dados que o Discriminador não possa distinguir dos reais.

**RESULTADO DESEJADO:** Gerador capaz de gerar dados indistinguíveis dos reais


# REDES AUTOENCODER



- Arquitetura de rede neural que reconstrói a entrada na saída;
- Composta por um codificador e um decodificador;
- Transforma a entrada em uma representação latente de menor dimensão;
- Útil para compressão de dados, remoção de ruídos e extração de características.




# REDES VARIACIONAIS AUTOENCODER (VAES)



- Extensão dos autoencoders com conceitos de inferência probabilística;
- Mapeiam a entrada em um espaço latente e introduzem uma distribuição probabilística;
- Treinamento envolve otimizar uma função de perda para se aproximar de uma distribuição pré-definida (geralmente gaussiana);
- Permite a geração de novas amostras semelhantes às observadas e exploração controlada do espaço latente.

# REDES TRANSFORMADORAS





- Arquitetura inovadora para gerar imagens realistas e de alta qualidade;
- Mecanismo de atenção permite capturar informações globais e locais na imagem;
- Autoatendimento entre os pixels permite modelar relações complexas;
- Estabilidade no treinamento é garantida por conexões residuais e normalização;
- Processamento eficiente possibilita a geração rápida de imagens.





# TREINAMENTO DOS ALGORÍTMOS



## 1 Uso de dados de treinamento

Para as GANs, é necessário um conjunto de dados com amostras reais representativas do domínio desejado. Já para Redes Autoencoder e Redes Transformadoras, são necessários pares de amostras de entrada e saída correspondentes. A qualidade dos dados de treinamento é essencial para o aprendizado de padrões relevantes.


## 2 Definição de hiperparâmetros

Parâmetros ajustáveis que controlam o comportamento do algoritmo de treinamento. São definidos antes do treinamento e afetam diretamente o desempenho do modelo. Alguns exemplos são o número de camadas e neurônios da rede e a taxa de aprendizado. Sua seleção adequada é crucial para obter resultados otimizados.

## 3 Otimização da função de perda

Usada para medir a discrepância entre as saídas previstas e as saídas reais no treinamento. Em GANs, é composta pela perda do gerador e a perda do discriminador. Em Redes Autoencoder, avalia a diferença entre as imagens de entrada e as imagens reconstruídas. Em Redes Transformadoras, inclui medidas de dissimilaridade entre as imagens de entrada e as imagens geradas.





- Melhoria da qualidade das imagens geradas com o aumento do número de épocas de treinamento
- Ajuste dos parâmetros e aprendizado de representações robustas durante o treinamento
- Captura de padrões nas imagens e geração de saídas mais realistas e de alta qualidade
- Cuidado com o overfitting, onde o modelo se ajusta demais aos dados de treinamento



# EXEMPLOS DE SOFTWARES





# DALL-E

## OpenAI

Figura 6: Logo OpenAI 2023.



Fonte: OpenAI, 2023.

Figura 7: Imagem gerada pela ferramenta DALL-E.



Fonte: OpenAI, 2023.



# ARTBREEDER

Figura 8: Logo ArtBreeder 2023.



Fonte: ArtBreeder, 2023.

Figura 9: Imagem gerada pela ferramenta ArtBreeder.




Fonte: ArtBreeder, 2023.



# THESE CATS DO NOT EXIST

Figura 10: Grade de imagens gerada pela ferramenta These Cats do not Exist.



Fonte: These Cats do not Exist, 2023.



- AI PAINTER
- DEPPAI
- TENSORFLOW







# DESAFIOS E LIMITAÇÕES





**TREINAMENTO  
ADEQUADO**

**COMPLEXIDADE  
COMPUTACIONAL**

**OVERFITTING**



**ESCOLHA DA  
ARQUITETURA**

**DIMENSIONALI-  
DADE DOS  
DADOS**





# APLICAÇÕES FUTURAS



**PERSONALIZAÇÃO DE  
EXPERIÊNCIAS  
CINEMATOGRÁFICAS**


**CRIAÇÃO DE  
MEMÓRIAS VIRTUAIS**

**GERAÇÃO DE IMAGENS  
COM BASE EM  
EMOÇÕES E  
SENSAÇÕES**


**GERAÇÃO DE ARTE E  
MÚSICA INOVADORAS**

**PERSONALIZAÇÃO DE  
MODA E DESIGN DE  
PRODUTOS**






ÉTICA



EVOLUÇÃO





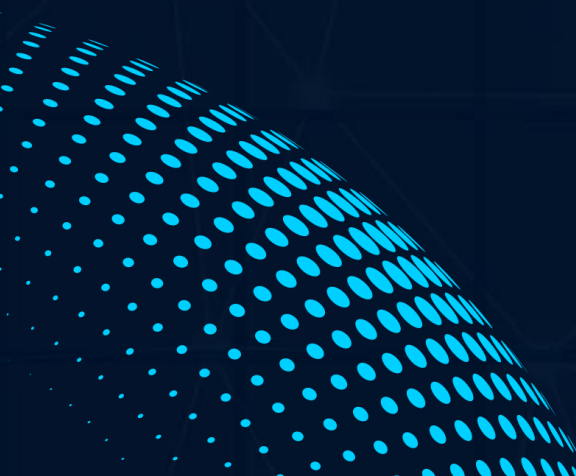
# CONCLUSÃO





# CONCLUSÃO



- Algoritmos de geração de imagens são uma área inovadora da inteligência artificial.
  - Utilizam técnicas como GANs, redes autoencoder e redes transformadoras.
  - Permitem criar imagens sintéticas de alta qualidade semelhantes às reais.
  - Aplicações práticas em entretenimento, medicina, publicidade e arte.
  - Desafios éticos
  - Colaboração entre especialistas em ética, tecnólogos e reguladores é essencial
- 





OBRIGADO!



# REFÊNCIAS BIBLIOGRÁFICAS



- FALK, Tiago; EIRAS, Mariana. Geração de Imagens Realistas com Redes Generativas Adversárias. Revista Brasileira de Computação Aplicada, v. 10, n. 2, p. 54-67, 2018.
- FORSTER, Carlos Henrique Q.; FERREIRA, Emmanoel. Arte Computacional e Geração de Imagens: Uma Análise Estética. Revista de Arte e Tecnologia, v. 4, n. 2, p. 45-60, 2018.
- NASCIMENTO, Thaís; MARINHO, Jéssica. A Influência da Geração de Imagens na Psicologia do Consumidor. Revista de Psicologia do Consumidor, v. 10, n. 2, p. 45-60, 2020.
- RIBEIRO, Marcelo. Geração de Imagens e o Futuro da Fotografia. Fotografia em Foco, v. 15, n. 3, p. 78-92, 2021.
- SANTIAGO, Gabriel., FERREIRA, Raoni. Geração de Imagens com Redes Neurais: Aplicações e Desafios. Revista Brasileira de Computação Aplicada, v. 10, n. 2, p. 45-62, 2018.
- SANTOS, Ana Lúcia da Costa. Ética na Inteligência Artificial: Reflexões sobre a Geração de Imagens. Revista de Ética e Filosofia Política, v. 28, n. 1, p. 120-135, 2021.
- SOUZA, Carlos E. R. de., ROCHA, Tarcisio da. Redes Generativas Adversárias Condicionais: Uma Revisão. Congresso Brasileiro de Computação (CBC), p. 123-136, 2020.